

A8_Series de tiempo no estacionarias

Héctor San Román Caraza


21/11/2022

```
data = data.frame(  
  "Año"=c(1,NA,NA,NA,2,NA,NA,NA,3,NA,NA,NA,4,NA,NA,NA),  
  "Trimestre"=c(1,2,3,4,1,2,3,4,1,2,3,4,1,2,3,4),  
  "Ventas(miles)"=c(4.8,4.1,6.0,6.5,5.8,5.2,6.8,7.4,6.0,5.6,7.5,7.8,6.3,5.9,8.0,8.4)  
)  
head(data,n=16)
```

##	Año	Trimestre	Ventas.miles.
## 1	1	1	4.8
## 2	NA	2	4.1
## 3	NA	3	6.0
## 4	NA	4	6.5
## 5	2	1	5.8
## 6	NA	2	5.2
## 7	NA	3	6.8
## 8	NA	4	7.4
## 9	3	1	6.0
## 10	NA	2	5.6
## 11	NA	3	7.5
## 12	NA	4	7.8
## 13	4	1	6.3
## 14	NA	2	5.9
## 15	NA	3	8.0
## 16	NA	4	8.4

Grafico de dispersion de los datos

```
t = 1:16  
plot(t, data$Ventas.miles., type = "o", col = "red", ylab = "Ventas", xlab = "Tiempo", main = "Ventas por año")
```




Haciendo un análisis básico de lo que vemos en la gráfica de dispersión podemos ver que existen ciertas tendencias en los trimestres de acuerdo al año. En los trimestres 1 y 2 de cada año vemos que tendremos mínimas en el año en cuanto a ventas. El trimestre 3 suele ser mucho mayor al trimestre 2 cada año. Vemos que pasa algo similar de trimestre 4 a 1, existe una baja cuando se acaba el 4 trimestre y se llega al 1 del próximo año.

Descomposición

```
Tiempo = ts(data$Ventas.miles., frequency = 4, start=c(2016, 1))
D =decompose(Tiempo, type = "m")
plot(D)
```

Decomposition of multiplicative time series



D

```
## $x
##   Qtr1 Qtr2 Qtr3 Qtr4
## 1  4.8  4.1  6.0  6.5
## 2  5.8  5.2  6.8  7.4
## 3  6.0  5.6  7.5  7.8
## 4  6.3  5.9  8.0  8.4
##
## $seasonal
##       Qtr1       Qtr2       Qtr3       Qtr4
## 1 0.9306617 0.8363763 1.0915441 1.1414179
## 2 0.9306617 0.8363763 1.0915441 1.1414179
## 3 0.9306617 0.8363763 1.0915441 1.1414179
## 4 0.9306617 0.8363763 1.0915441 1.1414179
##
## $trend
##       Qtr1       Qtr2       Qtr3       Qtr4
## 1      NA      NA 5.4750 5.7375
## 2 5.9750 6.1875 6.3250 6.4000
## 3 6.5375 6.6750 6.7625 6.8375
## 4 6.9375 7.0750      NA      NA
##
## $random
##       Qtr1       Qtr2       Qtr3       Qtr4
## 1      NA      NA 1.0039818 0.9925353
## 2 1.0430335 1.0048157 0.9849340 1.0129944
```


```
## 3 0.9861607 1.0030787 1.0160445 0.9994305
## 4 0.9757661 0.9970658      NA      NA
##
## $figure
## [1] 0.9306617 0.8363763 1.0915441 1.1414179
##
## $type
## [1] "multiplicative"
##
## attr(,"class")
## [1] "decomposed.ts"
```

Tendencia Lineal

```
N = lm(data$Ventas.miles.~t)
plot(t, data$Ventas.miles., type= "o", col = "red")
abline(N, col = "blue")
N
```

```
##
## Call:
## lm(formula = data$Ventas.miles. ~ t)
##
## Coefficients:
## (Intercept)          t
##      4.8525      0.1799
```

```
text(4,28,"ventas= 4.8525 + 0.1799 año")
```




Ventas Desestacionalizadas vs Tiempo

```
ventas_desestacionalizadas = (D$x)/(D$seasonal)
N2 = lm(ventas_desestacionalizadas~t)
print(summary(N2))
```

```
##
## Call:
## lm(formula = ventas_desestacionalizadas ~ t)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.5007 -0.1001  0.0037  0.1207  0.3872
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.10804    0.11171   45.73  < 2e-16 ***
## t            0.14738    0.01155   12.76 4.25e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.213 on 14 degrees of freedom
## Multiple R-squared:  0.9208, Adjusted R-squared:  0.9151
## F-statistic: 162.7 on 1 and 14 DF, p-value: 4.248e-09
```

```
plot(t, ventas_desestacionalizadas, type = "l")
abline(N2, col = "red")
text(10, 5.5, "ventas = 5.10804 + 0.14738 * trimestre")
```




El modelo se ajusta bien a los datos con una $r^2 = 0.9151$, lo que nos habla bien de la variabilidad explicada.

Significancia de B1

La \hat{B}_1 nos dicta la pendiente, o la inclinación, de nuestra ecuación de ajuste. Vemos que el P-value de este coeficiente es menor a 0.05, lo que nos dice que este valor es significativo.

Análisis de los residuos

```
qqnorm(N2$residuals)
qqline(N2$residuals)
```



Vemos que la línea de nuestro QQ PLOT nos dice que existe normalidad en nuestros residuos.

Prueba normalidad (Shapiro)

```
shapiro.test(N2$residuals)

##
##  Shapiro-Wilk normality test
##
## data:  N2$residuals
## W = 0.96379, p-value = 0.7307
```

Vemos que nuestro p-value no es menor a nuestro alfa de 0.05, con lo que podemos decir que existe normalidad en los datos.

Pronósticos para próximo año

```
f = function(x) {-3.5443 + 0.4847*x}
# Los índices estacionales son:
a1 = D$seasonal[1]
a2 = D$seasonal[2]
a3 = D$seasonal[3]
a4 = D$seasonal[4];
f(17)*a1
```

```
## [1] 4.370015
```

```
f(18)*a2
## [1] 4.33268
f(19)*a3
## [1] 6.183597
f(20)*a4
## [1] 7.019378
CME=mean(exp(2),na.rm=TRUE)
CME
## [1] 7.389056
```

Problema : “Un problemilla más”

```
df = data.frame(
  "Trimestre"=c(1,2,3,4),
  "Año 1"=c(1690,940,2625,2500),
  "Año 2"=c(1800,900,2900,2360),
  "Año 3"=c(1850,1100,2930,2615)
)
head(df, n=4)

##   Trimestre Año.1 Año.2 Año.3
## 1         1  1690  1800  1850
## 2         2   940   900  1100
## 3         3  2625  2900  2930
## 4         4  2500  2360  2615
```

a) Encuentre los promedios móviles de cuatro trimestres y los promedios móviles centrados

```
prom1 = sum(df$Año.1)/4
prom2 = sum(df$Año.2)/4
prom3 = sum(df$Año.3)/4

cat("Promedios móviles","\n")

## Promedios móviles
prom1

## [1] 1938.75
prom2

## [1] 1990
prom3

## [1] 2123.75
cat("Promedios móviles centrados","\n")

## Promedios móviles centrados
prom1c = mean(c(prom1,prom2))
prom2c = mean(c(prom2,prom3))
```



```
prom3c = mean(c(prom1c,prom2c))
```

```
prom1c
```

```
## [1] 1964.375
```

```
prom2c
```

```
## [1] 2056.875
```

```
prom3c
```


```
## [1] 2010.625
```

b) Calcule los índices estacionales de los cuatro trimestres

```
df2 = subset(df, select = -c(1) )  
head(df2)
```


```
##   Año.1 Año.2 Año.3  
## 1  1690  1800  1850  
## 2   940   900  1100  
## 3  2625  2900  2930  
## 4  2500  2360  2615
```

```
t= ts(df2, frequency = 2, start=c(2016,1)))  
plot.ts(t, col = "red")
```



```
D = decompose(t)  
plot(D, col = "red")
```

Decomposition of additive time series




D\$seasonal

```
## Time Series:
## Start = c(1, 1)
## End = c(6, 2)
## Frequency = 2
## [1] 600.4167 -600.4167 600.4167 -600.4167 600.4167 -600.4167 600.4167
## [8] -600.4167 600.4167 -600.4167 600.4167 -600.4167
```


c) ¿Cuándo obtiene la editorial el mayor índice estacional? ¿Parece razonable este resultado? ¿Por qué?

```
t= ts(df$Año.3, frequency = 2, start=c(2016,1))
plot.ts(t, col = "red")
```



```
D = decompose(t)
plot(D, col = "red")
```

Decomposition of additive time series



D\$seasonal

```
## Time Series:
## Start = c(1, 1)
## End = c(2, 2)
## Frequency = 2
## [1] 590.625 -590.625 590.625 -590.625
```

El mayor índice estacionario se obtiene en el 1ero y 3er trimestre del año. Estos índices lucen extraños, pues entre estos trimestres no se muestra variación alguna. Al hacer un análisis de vista en los datos vemos que en los trimestres 3 y 4 tenemos mayor venta que en los otros trimestres; sin embargo, del trimestre 2 al 3 vemos que existe un salto muy grande en ventas. Quizá estos índices nos dicen algo, pero ciertamente su interpretación hay que trabajarla más.